

# Diagnóstico de Câncer de Mama Baseado na Rede Neural de Kohonen

Weverson dos Santos Gomes<sup>1</sup>, Matheus Giovanni Pires<sup>1</sup>

<sup>1</sup>Departamento de Ciências Exatas – Universidade Estadual de Feira de Santana (UEFS)  
CEP 44.036-900 – Feira de Santana – BA – Brasil

kiko.ecomp@gmail.com, mgpires@ecomp.uefs.br

**Abstract.** *Second most common worldwide, breast cancer is the most common among women, accounting for 22% of new cases each year. If diagnosed and treated timely, the prognosis is relatively good. In Brazil, the mortality rates for breast cancer remain high, most likely because the disease is still diagnosed in advanced stages. Statistics indicate both increasing incidence in developed countries as in developing countries. Aiming to assist experts in the diagnosis of breast cancer, this work presents a system based on Kohonen Neural Network. The results show an accuracy rate above 98% in the diagnosis of breast cancer.*

**Resumo.** *Segundo tipo mais frequente no mundo, o câncer de mama é o mais comum entre as mulheres, respondendo por 22% dos casos novos a cada ano. Se diagnosticado e tratado oportunamente, o prognóstico é relativamente bom. No Brasil, as taxas de mortalidade por câncer de mama continuam elevadas, muito provavelmente porque a doença ainda é diagnosticada em estágios avançados. Estatísticas indicam aumento de sua incidência tanto nos países desenvolvidos quanto nos em desenvolvimento. Com o objetivo de auxiliar os especialistas no diagnóstico do câncer de mama, este trabalho apresenta um sistema baseado na Rede Neural de Kohonen, o qual obteve desempenho acima de 98%.*

## 1. Introdução

O câncer de mama é uma das doenças mais temidas entre as mulheres devido à sua frequência, alta taxa de mortalidade feminina em todo o mundo [Tahmouh 2007] e, sobretudo, pelos seus efeitos psicológicos, que afetam a percepção da sexualidade e a própria imagem pessoal. Só no Brasil, segundo o INCA (Instituto Nacional de Câncer), o número de mortes em 2010 foi de 12.852, sendo 147 homens e 12.705 mulheres. A estimativa de novos casos para 2012 foi de 52.680 [INCA 2013].

De acordo com INCA (2013), "No Brasil, as taxas de mortalidade por câncer de mama continuam elevadas, muito provavelmente porque a doença ainda é diagnosticada em estágios avançados. Na população mundial, a sobrevida média após cinco anos é de 61%". Como suas causas ainda não são bem conhecidas, a prevenção é a única maneira de reduzir a mortalidade de mulheres com câncer de mama, pois a detecção precoce aumenta as chances de cura substancialmente [Ball *et al.* 2004; Mavroforakis 2005].

A mamografia é considerada como o exame mais eficaz para a detecção do câncer de mama ainda impalpável devido a sua alta sensibilidade. No entanto, segundo

Giger (2000), de 10% a 30% das mulheres que apresentaram câncer de mama tiveram resultados negativos quando submetidas à mamografia, o que leva a crer que houve uma má interpretação dos exames. Distorções na interpretação e classificação de lesões por especialistas implicam um número maior de biópsias desnecessárias [Mavroforakis 2005; Bilska e Wolak 2005], ou seja, entre 65% a 85% das biópsias de mama são realizadas em lesões benignas [Kopans 1992]. Com isso, há uma redução na relação custo-benefício dos exames e, no pior caso, a não detecção da doença, caracterizando um diagnóstico falso-negativo.

A interpretação de lesões em uma mamografia é uma tarefa complexa para os especialistas, onde um diagnóstico preciso é diretamente dependente da experiência dos mesmos [Ball *et al.* 2004]. Além da complexidade na interpretação de lesões em uma mamografia, uma série de fatores influencia na interpretação de imagens mamográficas para um correto diagnóstico, tais como, baixo nível de contraste das imagens, nódulos com muitas variações de formas, tamanhos, contornos e densidade, além de possuírem muita semelhança com a densidade do tecido da mama [Menechelli *et al.* 2010a]. Outros fatores que geram problemas para uma análise precisa das imagens mamográficas são a descalibração do aparelho utilizado para fazer as medidas, a má qualidade das imagens geradas pelos aparelhos, as condições de manipulação e conservação do filme e, em imagens digitais, a digitalização da imagem a ser analisada pelo especialista [Ribeiro 2006].

Buscando minimizar esses problemas e auxiliar na detecção precoce do câncer de mama, vêm sendo desenvolvidos esquemas denominados CAD, Diagnóstico Auxiliado por Computador (do Inglês, *Computer-Aided Diagnosis*), com o objetivo de auxiliar o radiologista na interpretação das imagens mamográficas [Ribeiro *et al.* 2005; Porto *et al.* 2010; Marcomini *et al.* 2011]. Estes esquemas são sistemas computacionais que auxiliam no diagnóstico de pacientes e podem servir como uma segunda opinião aos radiologistas quanto à localização e à natureza dos nódulos mamários [Ribeiro *et al.* 2008a; Stemberg 2010]. Por isso, com o objetivo de auxiliar especialistas da área de análise de imagens mamográficas, este trabalho propõe o desenvolvimento de um esquema CAD baseado em Redes Neurais Artificiais, mais precisamente em mapas auto-organizáveis de Kohonen, para o auxílio no diagnóstico de câncer de mama em imagens mamográficas.

Este artigo está organizado da seguinte forma: na Seção 2 é descrita a forma mais comum de se prevenir o câncer de mama e a Seção 3 define o papel de um sistema CAD. Na Seção 4 é apresentada a rede neural de Kohonen e a metodologia empregada neste trabalho é apresentada na Seção 5. Os resultados obtidos são discutidos na Seção 6 e, por fim, as conclusões são apresentadas na Seção 7.

## **2. Mamografia**

O rastreamento é a única maneira de detectar e prevenir o câncer de mama precocemente. O instrumento mais efetivo para o diagnóstico precoce é a mamografia [Glingani e Ambrósio 2004; Marcomini *et al.* 2011], a qual pode reduzir em até 23% a taxa de mortalidade, dependendo do estágio em que for descoberta a doença, pois seu principal objetivo é a detecção de lesões não palpáveis ou a verificação de alterações na mama [Borghesan *et al.* 2003; Marcomini *et al.* 2011].

A mamografia constitui uma forma particular de radiografia, que trabalha com níveis de tensões e correntes em intervalos específicos, destinada a registrar imagens da mama a fim de diagnosticar a presença ou ausência de estruturas que possam indicar doenças [Mitchell *et al.* 1988]. O seu principal papel é o rastreamento de mulheres assintomáticas para a possível detecção do câncer de mama em um tamanho e estágio inicial, antes mesmo da própria observação da paciente ou do exame médico rotineiro.

A mamografia possui a vantagem de ser um método não invasivo, com imagens relativamente boas para um rastreamento e que leva um tempo relativamente pequeno para ser feito (Ribeiro 2006). As principais lesões identificadas na mamografia são as microcalcificações, um dos primeiros indícios de formação de tumores com grau elevado de suspeita de malignidade, e os nódulos, que são responsáveis por grande parte dos casos de câncer de mama (Ribeiro 2008a). Segundo Kopans (2000), os nódulos são encontrados em 39% dos casos de câncer não palpáveis. Na Figura 1 é ilustrado um exemplo de nódulo mamário.



**Figura 1. Exemplo de um nódulo mamário. Fonte: [Ribeiro 2006].**

### **3. Diagnóstico Auxiliado por Computador**

Os esquemas CAD (*Computer-Aided Diagnosis*) têm como objetivo fornecer uma “segunda opinião” ao radiologista, auxiliando-o na detecção de lesões suspeitas em uma mamografia. Além de analisar objetivamente essas lesões, em função de suas características de benignidade e malignidade, ele também auxilia na formulação do diagnóstico médico. Desta forma, suas principais finalidades são aumentar a eficiência do diagnóstico e do laudo mamográfico, diminuir o número de erros no diagnóstico (perdas ou biópsias desnecessárias) e, conseqüentemente, diminuir o número de mortes por câncer de mama [Chan *et al.* 1998, Giger 2004].

Entre as técnicas empregadas em um esquema CAD, um particular interesse remete às que buscam detectar e/ou classificar as microcalcificações [Jiang *et al.* 2007; Halkiotis *et al.* 2007; Jiang *et al.* 1998; Yu *et al.* 2006], nódulos e tumores [Schiabel *et al.* 2008; Ribeiro *et al.* 2007; Brzakovic *et al.* 1990; Younesi *et al.* 2007], além da utilização de técnicas de pré-processamento que visam aprimorar o contraste nas imagens mamográficas para melhorar a detecção das estruturas de interesse [Ram 1982; Nunes *et al.* 2002].

As principais etapas realizadas por um sistema CAD são a segmentação e a classificação. A etapa de segmentação de imagens refere-se ao processo de dividir a imagem em diversas partes elementares (objetos), permitindo a análise destas partes isoladamente [Gonzales e Woods 2000]. Após a segmentação, inicia-se a etapa de classificação dos objetos de interesse para o problema em questão. Para realizar esta classificação é necessária a extração e quantificação das características da imagem dos seus objetos constituintes [Ribeiro *et al.* 2007].

A classificação é formalmente definida como um processo pelo qual um padrão ou sinal recebido é atribuído a uma classe dentre um número predeterminado de classes (categorias) [Haykin 1999]. Muitas técnicas de classificação vêm sendo usadas em diversas aplicações, cada qual se adequando melhor para solucionar diferentes tipos de problemas. Especificamente em sistemas CAD para classificação de massas nodulares, as abordagens baseadas em Redes Neurais Artificiais, Sistemas Fuzzy e Redes Bayesianas vêm sendo utilizadas no diagnóstico do câncer de mama [Rose *et al.* 2010; Xie 2002].

#### **4. Redes Neurais Artificiais**

As Redes Neurais Artificiais (RNA) constituem-se em modelos computacionais inspirados na anatomia e funcionamento do cérebro humano. Estas redes são compostas por elementos processadores simples, chamados de neurônios artificiais, que imitam as mais elementares funções de um neurônio biológico e dos sistemas nervosos.


Os neurônios utilizados nos modelos de redes neurais realizam funções simples, como coletar os sinais existentes em suas entradas, agregá-los de acordo com sua função de entrada e produzir uma saída por intermédio de sua função de ativação inerente. Como exemplo de propriedades típicas do cérebro, as redes neurais aprendem a partir da experiência e generalizam novos exemplos a partir de exemplos prévios, abstraindo características essenciais de entrada [Haykin 1999].

Uma RNA realiza o reconhecimento de padrões passando inicialmente por uma seção de treinamento, durante a qual se apresenta repetidamente à rede um conjunto de padrões de entrada junto com a categoria à qual cada padrão particular pertence. Mais tarde, apresenta-se à rede um novo padrão que não foi visto antes, mas que pertence à mesma população de padrões utilizada para treinar a rede. A rede é capaz de identificar a classe daquele padrão particular por causa da informação que ela extraiu dos dados de treinamento [Rezende 2003].

##### **4.1. Redes de Kohonen**

As Redes de Kohonen, também conhecidas como Mapas Auto-Organizáveis de Kohonen (*Self-Organization Maps - SOM*), são redes que possuem uma estrutura reticulada de uma única camada, as quais são treinadas por um algoritmo competitivo [Kohonen 1984 *apud* Silva *et al.* 2010]. O processo de competição é baseado no critério de proximidade, ou seja, aquele neurônio que estiver mais próximo de determinado padrão  $x$  vencerá a competição [Silva *et al.* 2010]. Este neurônio é chamado de neurônio vencedor.

Na rede de Kohonen os neurônios se organizam em uma grade ou reticulado, geralmente bidimensional, podendo algumas vezes ser unidimensional [Braga *et al.* 2007]. Esta organização é definida pelo Mapa Topológico. Na Figura 2 é ilustrado um exemplo de mapa topológico bidimensional com  $N=3$ , onde o número de neurônio é igual a  $N.N$ .



**Figura 2. Mapa topológico da rede de Kohonen com  $N=3$ .**

Adicionalmente, as Redes de Kohonen possuem conexões laterais de acordo como o Mapa Topológico de Vizinhança. As conexões laterais modelam a competitividade entre os neurônios, onde apenas um será vencedor. A saída do neurônio vencedor pode influenciar ou colaborar com os seus neurônios vizinhos. Para os casos onde os neurônios estão mais próximos aos neurônios vencedores, o potencial dessas conexões laterais são maiores (excitatório). Por outro lado, quanto mais distantes dos neurônios vencedores, menor será o potencial destas conexões [Silva *et al.* 2010].

De acordo com Braga *et al.* (2007), a vizinhança de uma rede SOM pode assumir vários formatos, como por exemplo, quadrado, hexágono ou círculo (gaussiana), e a definição do formato dependerá do problema e da distribuição dos seus dados.

O principal objetivo de um SOM é mapear um conjunto de padrões de entrada, sendo cada um deles  $N$ -dimensional, para um mapeamento que pode ser representado em uma ou duas dimensões. A sua estrutura de configuração simples, assim como sua dinâmica de treinamento diferenciada, faz das redes de Kohonen uma ferramenta sofisticada para aplicações em problemas que envolvem classificação de padrões e identificação de agrupamentos de dados (*clustering*) [Silva *et al.* 2010].

## 5. Metodologia

O trabalho desenvolvido é baseado na rede neural auto-organizável proposto pelo finlandês Teuvo Kohonen. Os dados de treinamentos e testes da rede foram obtidos da base de dados “breast cancer wisconsin”, do repositório UCI Machine Learning, da Universidade da Califórnia, criada por Frank e Asuncion (2010).

Essa base de dados é bastante conhecida no meio científico e já foi utilizada em diversos outros trabalhos. Ela possui 699 amostras, as quais foram coletadas a partir de casos clínicos do Dr. Wolberg, da Universidade de Wisconsin. Cada amostra representa as informações de um determinado nódulo mamário, a qual possui 9 atributos (características), e mais dois atributos de identificação, isto é, o código da amostra e a classificação do nódulo, ou seja, se é um nódulo maligno ou benigno. Cada neurônio da rede possui nove entradas, que são os atributos das amostras.


Das 699 amostras disponíveis na base de dados, 16 não puderam ser utilizadas, pois faltavam informações referentes a algum atributo. Das 683 amostras restantes, 478 (equivalente a 70% do número total de amostras) foram utilizadas no processo de treinamento da rede e 205 (equivalente a 30% do número total de amostras) foram usadas nos testes da rede. Dessa forma, nenhuma amostra utilizada nos testes participou do processo de treinamento. O número total de amostras malignas é de 239 e de benignas é de 444, o que equivale a 35% e 65%, respectivamente, do conjunto de 683 amostras.

O conjunto de amostras usado no treinamento da rede contém 65% de amostras do tipo benigno e 35% do tipo maligno. Para o conjunto de teste se manteve a mesma proporção. A representatividade de cada classe (benigno e maligno) nos conjuntos de treinamento e teste é a mesma em relação ao conjunto total de amostras. Como há uma maior quantidade de amostras do tipo benigno, buscou-se preservar esta diferença nos conjuntos de treinamento e teste para evitar uma possível redução na representatividade da classe maligna, prejudicando o aprendizado da rede para esta classe.

O Mapa Topológico de Vizinhaça usado neste trabalho é uma função gaussiana, a qual é definida pela Equação 1 [Haykin 1999]. Na Figura 3 está ilustrada a função de vizinhaça gaussiana.

$$h_{j,i(x)} = \exp\left(\frac{d_{j,i}^2}{2\sigma^2}\right)$$

A função  $h_{j,i}$  é a distância do neurônio  $i$  para o neurônio vencedor  $j$ .  $d_{j,i}$  é a distância entre os neurônios  $j$  e  $i$ . O parâmetro  $\sigma$  é a largura da vizinhaça topológica, o qual mede o grau que os neurônios excitados na vizinhaça do neurônio vencedor participam do processo de aprendizagem [Haykin 1999].



**Figura 3. Função gaussiana de vizinhaça.**

Após o treinamento da rede de Kohonen, tem-se uma lista de neurônios vencedores, ou seja, para cada amostra utilizada no processo de treinamento da rede, há um neurônio vencedor associado a esta amostra. No entanto, falta ainda realizar a clusterização, ou seja, definir os agrupamentos e atribuir um rótulo a todos os neurônios

pertencentes a um mesmo agrupamento. Neste trabalho foi utilizado o algoritmo de agrupamento *K-Means* que, apesar de ser um algoritmo simples, satisfaz o problema, pois como será usada a base de dados “breast cancer wisconsin”, para treinar e testar a rede neural, já se sabe de antemão quantos grupos devem ser formados, que neste caso são dois, benigno e maligno. Sendo o conhecimento da quantidade de grupos uma condição necessária para o funcionamento do K-Means.

A análise utilizando o K-Means foi feita com o uso de recursos da ferramenta Matlab. Os demais recursos foram implementados e adicionados ao sistema desenvolvido.

## 6. Resultados e Discussão

No intuito de encontrar a topologia mais adequada para compor o classificador neural, foram realizados experimentos utilizando quantidades diferentes de neurônios, mais precisamente foram analisadas as topologias com 4, 9, 25, 100, 225, 400 e 625 neurônios.

Cada topologia foi testada cinco vezes e ao final das cinco execuções foram calculadas a média de acerto, o desvio padrão e a melhor e a pior taxa de acerto das cinco execuções. Os resultados estão descritos na Tabela 1.

**Tabela 1. Resultados obtidos para cada topologia testada.**

Topologia	Média de acerto (%)	Desvio padrão	Melhor taxa (%)	Pior taxa (%)
2x2 (4 neurônios)	98,53	0	98,53	98,53
3x3 (9 neurônios)	98,53	0	98,53	98,53
5x5 (25 neurônios)	98,53	0	98,53	98,53
10x10 (100 neurônios)	97,07	0	97,07	97,07
15x15 (225 neurônios)	96,78	1.14	97,56	96,09
20x20 (400 neurônios)	95,02	3.03	96,58	93,65
25x25 (625 neurônios)	94,73	3.34	96,58	92,19

Conforme mostrado na Tabela 1, as topologias com 4, 9 e 25 neurônios obtiveram as mais altas taxas de acerto. Além disso, não foram identificadas variações no percentual de acerto das topologias, por isso o desvio padrão para essas três topologias foi zero. É possível observar que a partir de 100 neurônios, a taxa de acerto começa a cair, e a partir de 225 neurônios o desvio padrão tende a aumentar.

De acordo com os resultados da Tabela 1, a melhor topologia é a 2x2 (4 neurônios). Apesar de as topologias 3x3 e 5x5 apresentarem a mesma taxa de acerto da topologia 2x2 e terem desvio padrão igual à zero, elas possuem um número maior de neurônios. Nestas situações, onde há topologias com o mesmo desempenho, recomenda-se sempre optar pela topologia mais otimizada, ou seja, com a menor quantidade de neurônios, pois estas demandam menos tempo para serem treinadas.

## 7. Conclusão

Neste trabalho foram apresentados os resultados de diagnósticos de câncer de mama realizados por um sistema baseado na rede neural de Kohonen. As informações para treinamento e teste da rede foram obtidas da base “breast cancer wisconsin”, do repositório UCI Machine Learning, da Universidade da Califórnia.

O sistema apresentou uma taxa de acerto acima de 98%, com desvio padrão igual à zero, o que demonstra confiabilidade e estabilidade nos resultados do sistema. Sendo assim, o sistema proposto pode contribuir, como uma segunda opinião, aos especialistas em análise de imagens mamográficas, para uma melhor interpretação das imagens e consequentemente, proporcionar um diagnóstico mais confiável ao paciente e evitando a realização de biópsias desnecessárias.

## Referências

- Ball, J.E., T.W. Butler, and L.M. Bruce. (2004). Towards Automated Segmentation and Classification of Masses in Digital Mammograms. In International Conference of the IEEE EMBS. San Francisco, CA, USA.
- Bilska-Wolak, A.O., et al. (2005). Computer aid for decision to biopsy breast masses on mammography: validation on new cases. *Academic Radiology*. 12(6): p. 669-670.
- Bottigli, U. and B. Golosio. (2002). Feature extraction from mammographic images using fast marching methods. *Nuclear Instruments and Methods in Physics Research A*. 487: p. 209–215.
- Braga, A. P.; Carvalho, A. P. L. F.; Ludermit, T. B. (2007) *Redes Neurais Artificiais: Teoria e Aplicações*, 2ª ed. LTC.
- Brzakovic, D., X.M. Luo, and P. Brzakovic. (1990). An approach to automated detection of tumors in mammograms. *IEEE Transactions on Medical Imaging*. 9(3): p. 233-241.
- Chan, H.P., et al. (1998). Computer-aided detection of microcalcifications in mammograms: methodology and preliminary clinical study. *Investigative Radiology*. 23(9): p. 664-671.
- Frank, A. e Asuncion, A. (2010). UCI Machine Learning Repository, <http://archive.ics.uci.edu/ml>, Irvine, CA: University of California, School of Information and Computer Science.
- Fukunaga, K. (1990). *Introduction to statistical pattern recognition*. Academic Press.
- Giger, M. L. (2000). Computer-aided diagnosis of breast lesions in medical images. *Computing in Science & Engineering*. 2(5): p. 39-45.
- Giger, M. L. (2004). Computerized analysis of images in the detection and diagnosis of breast cancer. *Seminars in Ultrasound, CT and MRI*. 25: p. 411-418.
- Gonzales, R.C. and R.E. Woods. (2000). *Processamento de imagens digitais*. 1ª ed. Edgard Blücher.



- Halkiotis, S., T. Botsis, e M. Rangoussi. (2007). Automatic detection of clustered microcalcifications in digital mammograms using mathematical morphology and neural networks. *Signal Processing*. 87(7): p. 1559-1568.
- Haykin, S. (1999). *Neural Networks - A Comprehensive Foundation*. 2ª ed. New York: Prentice-Hall.
- INCA (2013). "Tipos de Câncer: Mama". Instituto Nacional de Câncer. URL: <http://www2.inca.gov.br/wps/wcm/connect/tiposdecancer/site/home/mama>. Acesso em 21/02/2013.
- Jiang, Y., R. M. Nishikawa, and J. Papaioannou. (1998). Requirement of microcalcification detection for computerized classification of malignant and benign clustered microcalcifications. in *SPIE*.
- Jiang, J., B. Yao, e A.M. Wason. (2007). A genetic algorithm design for microcalcification detection and classification in digital mammograms. *Journal of the Computerized Medical Imaging and Graphics*. 31(1): p. 49–61.
- Karssemeijer, N., et al. (2003). Computer-aided detection versus independent double reading of masses on mammograms. *Radiology*. 227: p. 192-200.
- Kopans, D.B. (1992). The positive predictive value of mammography. *American Journal of Roentgenology*. vol.158, nro.3, p.521-526.
- Kopans, D.B. (2000). *Imagem da Mama*. in MEDSI. Rio de Janeiro.
- Mavroforakis, M., et al. (2005). Significance analysis of qualitative mammographic features, using linear classifiers, neural networks and support vector machines. *European Journal of Radiology*. 54(1): p. 80-89.
- Mitchell JR., G.W. and L.W. Basset. (1988). *Mastologia Prática*. Revinter.
- Mudigonda, N.R., R.M. Rangayyan, and J.E.L. Desautels. (2001). Detection of Breast Masses in Mammograms by Density Slicing and Texture Flow-Field Analysis. *IEEE Transactions on Medical Imaging*. 20(12): p. 1215-1227.
- Nunes, F.L.S. (2001). *Investigações em Processamento de Imagens Mamográficas para Auxílio ao Diagnóstico de Mamas Densas*. Instituto de Física de São Carlos, Universidade de São Paulo, São Carlos.
- Nunes, F.L.S., H. Schiabel, and R.H. Benatti. (2002). Contrast enhancement in dense breast images using the modulation transfer function. *Medical Physics*. 29(12): p. 2925-2936.
- Pichiliani, M. (2006). *Data Mining na Prática: Algoritmo K-Means*, <http://imasters.com.br/artigo/4709/sql-server/data-mining-na-pratica-algoritmo-k-means/>.
- Ram, G. (1982). Optimization of ionizing radiation usage in medical imaging by means of image enhancement techniques. *Medical Physics*. vol.9, p.733-737.
- Rezende, S.O. (2003). *Sistemas Inteligentes - Fundamentos e Aplicações*. 1ª ed. Manoele.

- Ribeiro, P.B., et al. (2007). Selection of the Best Features for the Classification of Contour of Mammary Nodules Using Artificial Neural Networks. in Society for Imaging Informatics in Medicine. Providence, Rhode Island.
- Rose, D.C., et al. (2010). Applying Deep-Layered Clustering to Mammography Image Analytics. in Biomedical Sciences and Engineering Conference (BSEC).
- Schiabel, H., V.T. Santos, and M.F. Angelo. (2008). Segmentation technique for detecting suspect masses in dense breast digitized images as a tool for mammography CAD schemes. in Applied Computing.
- Silva, I. N., Spatti, D.H., Flauzino, R.A. (2010). Redes Neurais Artificiais: para engenharia e ciências aplicadas. São Paulo: Artliber.
- Tahmoush, D. (2007) Image differencing approaches to medical image classification. In: 36<sup>th</sup> IEEE Applied Imagery Pattern Recognition Workshop - AIPR, Washington, p.22-27.
- Thurfjell, E.L., K.A. Lenervall, and A.A. Taube. (1994). Benefit of independent double reading in a population-based mammography screening program. Radiology. 191: p. 241-244.
- Xie, M. (2002). A method of tumors detection in digital mammography. in International Conference on Communications, Circuits and Systems and West Sino Expositions.
- Younesi, F., et al. (2007). Computer-Aided Mass Detection on Digitized Mammograms Using Adaptive Thresholding and Fuzzy Entropy. in Engineering in Medicine and Biology Society. Lyon, França.
- Yu, S., K. Li, and Y. Huang. (2006). Detection of microcalcifications in digital mammograms using wavelet filter and Markov random field model. Computerized Medical Imaging and Graphics. 30: p. 163-173.